

Diszkrét matematika II.


8. előadás

Fancsali Szabolcs Levente
nudniq@inf.elte.hu

ELTE IK Komputeralgebra Tanszék

Mérai László diái alapján

A kommunikáció során információt hordozó adatokat viszünk át egy csatornán keresztül az információforrástól, az adótól az információ címzettjéhez, a vevőhöz.



A kommunikáció vázlatos ábrája

Megjegyzés

Az információ átvitele térben és időben történik. Egyes esetekben az egyik, más esetekben a másik dimenzió a domináns (pl. telefonálás; információ rögzítése adathordozóra, majd későbbi visszaolvasása).

Definíció

Az **információ** új ismeret. Shannon nyomán az általa megszüntetett bizonytalansággal mérjük.

Definíció

Tegyük fel, hogy egy információforrás nagy számú, összesen n üzenetet bocsát ki. Az összes ténylegesen előforduló különböző üzenet legyen

a_1, a_2, \dots, a_k .

Ha az a_j üzenet m_j -szer fordul elő, akkor azt mondjuk, hogy a **gyakorisága** m_j , **relatív gyakorisága** pedig $p_j = \frac{m_j}{n} > 0$.

A p_1, p_2, \dots, p_k szám k -ast az **üzenetek eloszlásának** nevezzük ($\sum_{j=1}^k p_j = 1$).

Az a_j üzenet **egyedi információtartalma** $I_j = -\log_r p_j$, ahol r egy 1-nél nagyobb valós szám, ami az **információ egységét** határozza meg. Ha $r = 2$, akkor az információ egysége a **bit**.

Az üzenetforrás által kibocsátott üzenetek **átlagos információtartalma**, vagyis $H_r(p_1, p_2, \dots, p_k) = -\sum_{j=1}^k p_j \log_r p_j$ a forrás **entrópiája**. Ez csak az üzenetek eloszlásától függ, a tartalmuktól nem.

Egy k tagú **eloszlásnak** olyan pozitív valós számokból álló p_1, p_2, \dots, p_k sorozatot nevezünk, amelyre $\sum_{j=1}^k p_j = 1$. Ennek az eloszlásnak az **entrópiája** $H_r(p_1, p_2, \dots, p_k) = -\sum_{j=1}^k p_j \log_r p_j$.

Definíció

Legyen $I \subset \mathbb{R}$ egy intervallum. Az $f : I \rightarrow \mathbb{R}$ függvényt konvexnek nevezzük, ha bármely $x_1, x_2 \in I$ és $0 \leq t \leq 1$ esetén

$$f(tx_1 + (1-t)x_2) \leq tf(x_1) + (1-t)f(x_2).$$

f szigorúan konvex, ha egyenlőség csak $t = 0$ vagy $t = 1$ esetén lehetséges.

Lemma (Jensen-egyenlőtlenség, NB)

Legyen p_1, p_2, \dots, p_k egy eloszlás, $f : I \rightarrow \mathbb{R}$ pedig egy szigorúan konvex függvény az $I \subset \mathbb{R}$ intervallumon. Ekkor $q_1, q_2, \dots, q_k \in I$ esetén

$$f\left(\sum_{j=1}^k p_j q_j\right) \leq \sum_{j=1}^k p_j f(q_j),$$

és egyenlőség pontosan akkor áll fenn, ha $q_1 = q_2 = \dots = q_k$.

Tétel

Bármilyen eloszláshoz tartozó entrópiára

$$H_r(p_1, p_2, \dots, p_k) \leq \log_r k,$$

és egyenlőség pontosan akkor teljesül, ha $p_1 = p_2 = \dots = p_k = \frac{1}{k}$.

Bizonyítás

$r > 1$ esetén a $-\log_r(x)$ függvény szigorúan konvex, ezért használhatjuk a lemmát $q_j = \frac{1}{p_j}$ választással:

$$\begin{aligned} -H_r(p_1, p_2, \dots, p_k) &= \sum_{j=1}^k p_j \log_r p_j = \\ &= \sum_{j=1}^k p_j \left(-\log_r \frac{1}{p_j} \right) \geq -\log_r \left(\sum_{j=1}^k p_j \frac{1}{p_j} \right) = -\log_r k. \end{aligned}$$

Definíció

A **kódolás** alatt a legáltalánosabb értelemben az üzenetek halmazának egy másik halmazba való leképezését értjük.

Ha a leképezés injektív, akkor azt mondjuk, hogy a kódolás **felbontható**, **egyértelműen dekódolható**, vagy **veszteségmentes**, egyébként **veszteségesnek** nevezzük, mert információvesztéssel jár.

Betűnkénti kódolás

A betűnkénti kódolás során az üzenetet meghatározott módon egymáshoz átfedés nélkül csatlakozó részekre bontjuk, egy-egy ilyen részt egy szótár alapján kódolunk, és az így kapott kódokat az eredeti sorrendnek megfelelően egymáshoz láncoljuk.

Az általánosság csorbítása nélkül feltehetjük, hogy a szótár alapján kódolandó elemi üzenetek egy **A** **ábécé** (a **kódolandó ábécé**) **betűi**, és egy-egy ilyen betű kódja egy másik (az előbbitől nem feltétlenül különböző) **B** **ábécé** (**kódoló ábécé** vagy **kódábécé**) betűivel felírt **szó**, vagyis ezen ábécéből vett betűk véges sorozata, a sorozat elemeit egyszerűen egymás mellé írva. Az ábécékről feltesszük, hogy nem-üresek és végesek.

Definíció

Az **A** ábécé betűivel felírható összes (legalább egy betűt tartalmazó) szó halmazát A^+ jelöli, míg az egyetlen betűt sem tartalmazó **üres szóval** (jele: \emptyset vagy λ) kibővített halmazt A^* .

Betűnkénti kódolás

Definíció

A betűnkénti kódolást egy $\varphi : A \rightarrow B^*$ leképezés határozza meg, amelyet természetes módon terjesztünk ki egy $\psi : A^* \rightarrow B^*$ leképezéssé:

$a_1 a_2 \dots a_n = \alpha \in A^*$ esetén $\psi(\alpha) = \varphi(a_1) \varphi(a_2) \dots \varphi(a_n)$.

$\text{rng}(\psi)$ -t **kódnak** nevezzük, elemei a **kódszavak**.

Megjegyzés

Ha φ nem injektív, vagy az üres szó benne van az értékkészletében, akkor a kapott ψ kódolás nem injektív (Miért?), tehát nem felbontható, ezért betűnkénti kódolásnál feltesszük, hogy φ injektív, és B^+ -ba képez.

Betűnkénti kódolás

Definíció

Tekintsünk egy A ábécét, és legyen $\alpha, \beta, \gamma \in A^*$. Ekkor α **prefixe** (**előtagja**), míg γ **szuffixe** (**utótagja**) $\alpha\gamma$ -nak, β pedig **infixe** (**belső tagja**) $\alpha\beta\gamma$ -nak.

Definíció

Prefixmentes halmaznak nevezzük szavak egy halmazát, ha nincs benne két különböző szó, hogy egyik a másik prefixe.

Definíció

Az üres szó és α prefixe, szuffixe és infixe is α -nak, ezeket α **triviális prefixeinek**, **triviális szuffixeinek** és **triviális infixeinek** nevezzük.

Definíció

α egy prefixét, szuffixét, illetve infixét **valódi prefixnek**, **valódi szuffixnek**, illetve **valódi infixnek** nevezzük, ha nem egyezik meg α -val.

Betűnkénti kódolás

Definíció

Tekintsük az injektív $\varphi : A \rightarrow B^+$ leképezést, illetve az általa meghatározott ψ betűnkénti kódolást.

Ha $\text{rng}(\varphi)$ prefixmentes halmaz, akkor **prefix kódról** beszélünk.

Ha $\text{rng}(\varphi)$ elemei azonos hosszúságúak, akkor **egyenletes kódról**, **fix hosszúságú kódról**, esetleg **blokk-kódról** beszélünk.

Vesszős kódról beszélünk, ha van egy olyan $\vartheta \in B^+$ szó (a **vessző**), amely minden kódszónak szuffixe, de egyetlen kódszó sem áll elő $\alpha\vartheta\beta$ alakban nem üres β szóval.

Állítás

Prefix kód felbontható.

Bizonyítás

Konstruktív: nézzük az eddig beérkezett szimbólumokból összeálló szót. Amint ez kiadja a kódolandó ábécé valamely betűjének a kódját, azonnal dekódolhatunk a megfelelő betűre, mert a folytatásával kapott jelsorozat egyetlen betűnek sem lehet a kódja.

Betűnkénti kódolás

Állítás

Egyenletes kód prefix (így nyilván felbontható is).

Bizonyítás

Mivel a kódszavak hossza azonos, ezért csak úgy lehet egy kódszó prefixe egy másiknak, ha megegyeznek.

Állítás

Vesszős kód prefix (így nyilván felbontható is).

Bizonyítás

A vessző egyértelműen jelzi egy kódszó végét, hiszen ha folytatva kódszót kapnánk, abban a vessző tiltott módon szerepelne.

Betűnkénti kódolás

Példák

Legyen $A = \{a,b,c\}$, $B = \{0,1\}$, $\varphi : A \rightarrow B^+$ pedig az alábbi módon definiált.

	1.	2.	3.	4.	5.	6.
$\varphi(a)$	01	1	01	0	00	01
$\varphi(b)$	1101	01	011	10	10	001
$\varphi(c)$	01	10	11	11	11	0001

1. $\varphi(a) = \varphi(c) \implies \varphi$ nem injektív
2. $\psi(ab) = 101 = \psi(ca) \implies$ nem felbontható
3. nem prefix, de felbontható
4. prefix
5. egyenletes
6. vesszős

Betűnkénti kódolás

Tétel (McMillan-egyenlőtlenség, NB)

Legyen $A = \{a_1, a_2, \dots, a_n\}$ és B két ábécé, B elemeinek száma $r \geq 2$, és $\varphi : A \rightarrow B^+$ injektív leképezés.

Ha a φ által meghatározott betűnkénti kódolás felbontható, akkor $\ell_j = |\varphi(a_j)|$ jelöléssel

$$\sum_{j=1}^n \frac{1}{r^{\ell_j}} \leq 1.$$

Tétel (McMillan-egyenlőtlenség „megfordítása”, NB)

Az előző tétel jelöléseit használva, ha $\ell_1, \ell_2, \dots, \ell_n$ olyan pozitív egész számok, hogy $\sum_{j=1}^n r^{-\ell_j} \leq 1$, akkor van az A -nak a B elemeivel való olyan felbontható (sőt prefix) kódolása, hogy az a_j betű kódjának hossza ℓ_j .

Betűnkénti kódolás

Tétel (McMillan-egyenlőtlenség, NB)

Legyen $A = \{a_1, a_2, \dots, a_n\}$ és B két ábécé, B elemeinek száma $r \geq 2$, és $\varphi : A \rightarrow B^+$ injektív leképezés.

Ha a φ által meghatározott betűnkénti kódolás felbontható, akkor $\ell_j = |\varphi(a_j)|$ jelöléssel

$$\sum_{j=1}^n r^{-\ell_j} \leq 1.$$

Tétel (McMillan-egyenlőtlenség „megfordítása”, NB)

Az előző tétel jelöléseit használva, ha $\ell_1, \ell_2, \dots, \ell_n$ olyan pozitív egész számok, hogy $\sum_{j=1}^n r^{-\ell_j} \leq 1$, akkor van az A -nak a B elemeivel való olyan felbontható (sőt prefix) kódolása, hogy az a_j betű kódjának hossza ℓ_j .

Betűnkénti kódolás

Definíció

Legyen $A = \{a_1, a_2, \dots, a_n\}$ a kódolandó ábécé, p_1, p_2, \dots, p_n a betűk eloszlása, $\varphi : A \rightarrow B^+$ injektív leképezés, továbbá $\ell_j = |\varphi(a_j)|$.

Ekkor $\bar{\ell} = \sum_{j=1}^n p_j \ell_j$ a **kód átlagos szóhossza**.

Ha adott elemszámú ábécével és eloszlással egy felbontható betűnkénti kód átlagos szóhosszúsága minimális, akkor **optimális kódnak** nevezzük.

Megjegyzés

Az átlagos kódhossz valós szám, és valós számok halmazában nem feltétlenül van minimális elem (ld. $\{\frac{1}{n} | n \in \mathbb{N}\}$), ezért optimális kód létezése nem triviális.

Betűnkénti kódolás

Állítás

Adott ábécé és eloszlás esetén létezik optimális kód.

Bizonyítás

Válasszunk egy tetszőleges felbontható kódot (Miért van ilyen?), ennek átlagos szóhosszúsága legyen ℓ . Mivel $p_j \ell_j > \ell$ esetén a kód nem lehet optimális (Miért?), ezért elég azokat a kódokat tekinteni, amelyekre $\ell_j \leq \frac{\ell}{p_j}$, ha $j = 1, 2, \dots, n$. Ilyen kód csak véges sok van, így van köztük minimális átlagos hosszúságú.

Betűnkénti kódolás

Tétel (Shannon tétele zajmentes csatornára)

Legyen $A = \{a_1, a_2, \dots, a_n\}$ a kódolandó ábécé, p_1, p_2, \dots, p_n a betűk eloszlása, $\varphi : A \rightarrow B^+$ injektív leképezés, B elemeinek a száma $r \geq 2$, továbbá $\ell_j = |\varphi(a_j)|$.

Ha a φ által meghatározott betűnkénti kódolás felbontható, akkor $H_r(p_1, p_2, \dots, p_n) \leq \bar{\ell}$.

Bizonyítás

$$\begin{aligned}\bar{\ell} - H_r(p_1, p_2, \dots, p_n) &= \sum_{j=1}^n p_j \ell_j + \sum_{j=1}^n p_j \log_r p_j = \\ &= \sum_{j=1}^n p_j \cdot (-\log_r(r^{-\ell_j})) + \sum_{j=1}^n p_j \cdot \left(-\log_r \frac{1}{p_j}\right) = \sum_{j=1}^n p_j \cdot \left(-\log_r \frac{r^{-\ell_j}}{p_j}\right) \geq \\ &\geq -\log_r \left(\sum_{j=1}^n r^{-\ell_j}\right) \geq -\log_r 1 = 0\end{aligned}$$

Betűnkénti kódolás

Tétel (Shannon kód létezése)

Az előző tétel jelöléseivel, ha $n > 1$, akkor van olyan prefix kód, amire $\bar{\ell} < H_r(p_1, p_2, \dots, p_n) + 1$.

Bizonyítás

Válasszunk olyan $\ell_1, \ell_2, \dots, \ell_n$ természetes számokat, amelyekre $r^{-\ell_j} \leq p_j < r^{-\ell_j+1}$, ha $j = 1, 2, \dots, n$ (Miért tudunk ilyeneket választani?). Ekkor $\sum_{j=1}^n r^{-\ell_j} \leq \sum_{j=1}^n p_j = 1$, így a McMillan-egyenlőtlenség megfordítása miatt létezik prefix kód az adott ℓ_j hosszakkal. Mivel $\ell_j < 1 - \log_r p_j$ (Miért?), ezért

$$\bar{\ell} = \sum_{j=1}^n p_j \ell_j < \sum_{j=1}^n p_j (1 - \log_r p_j) = 1 + H_r(p_1, p_2, \dots, p_n).$$

Optimális kódkonstrukció: Huffman-kód

Legyen $\{a_1, a_2, \dots, a_n\}$ az üzenetek halmaza, a hozzájuk tartozó eloszlás pedig $\{p_1, p_2, \dots, p_n\}$, a kódábécé elemszáma r .

Rendezzük relatív gyakoriság szerint csökkenő sorrendbe a betűket.

Osszuk el maradékosan $n - 2$ -t $r - 1$ -gyel:

$n - 2 = q(r - 1) + m$ $0 \leq m < r - 1$, és legyen $t = m + 2$.

Helyettesítsük az utolsó t betűt egy új betűvel, amihez az elhagyott betűk relatív gyakoriságainak összegét rendeljük, és az így kapott gyakoriságoknak megfelelően helyezzük el az új betűt a sorozatban.

Ezek után ismételjük meg az előző redukciót, de most már minden lépésben r betűvel csökkentve a kódolandó halmazt, mígnem már csak r betű marad.

Most a redukált ábécé legfeljebb r betűt tartalmaz, és ha volt redukció, akkor pontosan r -et.

Ezeket a kódoló ábécé elemeivel kódoljuk, majd a redukciónak megfelelően visszafelé haladva, az összevont betűk kódját az összevonásként kapott betű már meglévő kódjának a kódoló ábécé különböző betűivel való kiegészítésével kapjuk.

Példa Huffman-kódra

Legyen $A = \{a, b, \dots, j\}$, a relatív gyakoriságok

0, 17; 0, 02; 0, 13; 0, 02; 0, 01; 0, 31; 0, 02; 0, 17; 0, 06; 0, 09, a kódoló ábécé pedig $\{0, 1, 2\}$. $10 - 2 = 4 \cdot (3 - 1) + 0$, így $t = 0 + 2 = 2$.

f	0,31
a	0,17
h	0,17
c	0,13
j	0,09
i	0,06
b	0,02
d	0,02
g	0,02
e	0,01

} 0, 03

f	0,31
a	0,17
h	0,17
c	0,13
j	0,09
i	0,06
(g,e)	0,03
b	0,02
d	0,02

} 0, 07

f	0,31
a	0,17
h	0,17
c	0,13
j	0,09
((g,e),b,d)	0,07
i	0,06

} 0, 22

f	0,31
(j,((g,e),b,d),i)	0,22
a	0,17
h	0,17
c	0,13

} 0, 47

(a,h,c)	0,47
f	0,31
(j,((g,e),b,d),i)	0,22

Példa Huffman-kódra folyt.

(a,h,c)	0,47
f	0,31
$(j,((g,e),b,d),i)$	0,22

Kódolás:

$(a,h,c) \mapsto 0$	$a \mapsto 00$		
	$h \mapsto 01$		
	$c \mapsto 02$		
$f \mapsto 1$			
$(j,((g,e),b,d),i) \mapsto 2$	$j \mapsto 20$		
	$((g,e),b,d) \mapsto 21$	$(g,e) \mapsto 210$	$g \mapsto 2100$
			$e \mapsto 2101$
		$b \mapsto 211$	
		$d \mapsto 212$	
	$i \mapsto 22$		

Entrópia: $\approx 1,73$.

Átlagos szóhossz: $1,79$.

Betűnkénti kódolás

Tétel (NB)

A Huffman-kód optimális.

Példa Shannon-kódra

Az előző példában használt ábécét és eloszlást fogjuk használni.
Rendezzük sorba az ábécét relatív gyakoriságok szerinti csökkenő sorrendben:

f	0,31
a	0,17
h	0,17
c	0,13
j	0,09
i	0,06
b	0,02
d	0,02
g	0,02
e	0,01

Példa Shannon-kódra folyt.

Határozzuk meg a szükséges szóhosszúságokat:

$\frac{1}{9} \leq 0,31; 0,17; 0,13 < \frac{1}{3}$, ezért f, a, h és c kódhossza 2.

$\frac{1}{27} \leq 0,09; 0,06 < \frac{1}{9}$, ezért j és i kódhossza 3.

$\frac{1}{81} \leq 0,02 < \frac{1}{27}$, ezért b, d és g kódhossza 4.

$\frac{1}{243} \leq 0,01 < \frac{1}{81}$, ezért e kódhossza 5.

Az f kódja 00, az a kódja 01, a h kódja 02, és ez utóbbihoz 1-et adva hármas alapú számrendszerben kapjuk c kódját, ami 10. Ehhez 1-et adva 11-et kapunk, de j kódjának hossza 3, ezért ezt még ki kell egészíteni jobbról egy 0-val, tehát j kódja 110. Hasonlóan folytatva megkapjuk a teljes kódot:

f	00
a	01
h	02
c	10
j	110
i	111
b	1120
d	1121
g	1122
e	12000

Átlagos szóhossz: $2,3 < 1,73 + 1$.

Betűnkénti kódolás

Kódfa

A betűnkénti kódolás szemléltethető egy címkézett irányított fával.

Legyen $\varphi : A \rightarrow B^*$ egy betűnkénti kódolás, és tekintsük $\text{rng}(\varphi)$ prefixeinek halmazát. Ez a halmaz részbenrendezett a „prefixe” relációra. Vegyük ennek a Hasse-diagramját. Így egy irányított fát kapunk, aminek a gyökere az üres szó, és minden szó a hosszának megfelelő szinten van.

A fa éleit címkézzük úgy B elemeivel, hogy ha $\beta = \alpha b$ valamely $b \in B$ -re, akkor az α -ból β -ba vezető él címkéje legyen b .

A kódfa csúcsait is megcímkézhethetjük: az $a \in A$ kódjának megfelelő csúcs címkéje legyen $a \in A$; azon csúcs címkéje, amely nincsen $\text{rng}(\varphi)$ -ben, legyen „üres”.


Megjegyzés

Az előbbi konstrukció meg is fordítható. Tekintsünk egy véges, élcímkézett irányított fát, ahol az élcímkék halmaza B , az egy csúcsból kiinduló élek mind különböző címkéjűek, továbbá az A véges ábécének a csúcsokra való leképezését, amelynél minden levél előáll képként.

Az $a \in A$ betű kódja legyen az a szó, amelyet úgy kapunk, hogy a gyökértől az a -nak megfelelő csúsig haladó irányított út mentén összeolvassuk az élek címkéit.

Kódfa

Példa



A Huffman-kódos példában szereplő kódhoz tartozó kódfa.


$\varphi(a) = 00$, $\varphi(b) = 211$, $\varphi(c) = 02$, $\varphi(d) = 212$, $\varphi(e) = 2101$, $\varphi(f) = 1$,
 $\varphi(g) = 2100$, $\varphi(h) = 01$, $\varphi(i) = 22$, $\varphi(j) = 20$.

A kódszavak prefixeinek halmaza:

$\{\lambda, 1, 00, 0, 01, 02, 20, 2, 22, 211, 21, 212, 2100, 210, 2101\}$

Kódfa

Példa



A Shannon-kódos példában szereplő kódhoz tartozó kódfa.

$\varphi(a) = 01$, $\varphi(b) = 1120$, $\varphi(c) = 10$, $\varphi(d) = 1121$, $\varphi(e) = 12000$,

$\varphi(f) = 00$, $\varphi(g) = 1122$, $\varphi(h) = 02$, $\varphi(i) = 111$, $\varphi(j) = 110$.

A kószavak prefixeinek halmaza:

$\{01, 0, \lambda, 1120, 112, 11, 1, 10, 1121, 12000, 1200, 120, 12, 00, 1122, 02, 111, 110\}$